



Quanto costa un token?

FinOps per l'AI in produzione

Emanuele Garofalo

CEO & CTO Magneticode · Microsoft MVP categoria Azure





In due anni il "problema" si è palesato a tutti

98%

dei team FinOps

gestisce spesa AI nel 2026.
Era il 31% nel 2024

3,2×

in un anno

spesa GenAI delle aziende: **da 11,5 a 37 mld** di dollari, 2024-2025

6%

ci riesce

solo il 6% attribuisce all'AI più del 5% dell'EBIT.
L'88% la usa

« La vostra AI crea valore? Non tutti hanno la risposta. »

State of FinOps 2026 · Menlo Ventures, State of GenAI in the Enterprise 2025 · McKinsey State of AI 2025

FinOps in una slide

- 1 Capire (Inform)**
Visibilità, allocazione, economia unitaria. Sapere cosa spendete e per conto di chi
- 2 Agire (Optimize)**
Le leve architetturali e quelle tariffarie. In quest'ordine, per l'AI
- 3 Rendere continuo (Operate)**
Governance, responsabilità distribuita, decisioni che si ripetono senza di voi
- 4 Cosa FinOps non è**
Non è tagliare i costi. È decidere consapevolmente quanto vale la pena spendere

Tokenomics: il nome che ha preso "questa cosa"

Tokenomics ovvero “FinOps applicato all’AI”



Cosa governa il FinOps classico

Il costo variabile dell'infrastruttura: calcolo, archiviazione, rete



Cosa governa la tokenomics

Il costo variabile del calcolo "intelligente"



Cosa cambia?

La risorsa è probabilistica e non deterministica, e si paga per atto inferenziale

J.R. Storment, direttore esecutivo FinOps Foundation · Token Economics: The Atomic Unit of AI Value

L'AI non ha (avrebbe) un framework FinOps a parte

-  **Acquisizione dati (Data Ingestion)**
Più incertezza sui dati di costo e competenze diverse da quelle cloud tradizionali
-  **Allocazione (Allocation)**
Difficile capire chi consuma l'output del modello. Più interfacce, meno tracciabilità
-  **Reportistica e analisi (Reporting & Analytics)**
Metriche nuove e specifiche, e una platea di interlocutori molto più ampia
-  **Pianificazione e stima (Planning & Estimating)**
Entrano in gioco soglie di qualità e accuratezza del modello, non solo volumi
-  **Previsione (Forecasting)**
Prevedibilità bassa, soprattutto nelle fasi iniziali di un progetto
-  **Ottimizzazione tariffaria (Rate Optimization)**
Modelli tariffari dei fornitori molto più dinamici, con in più il fattore scarsità

FinOps Foundation · FinOps for AI Overview

Attenzione: costo dell'AI non è costo dei token

confessione ho barato sul titolo del talk

- **1 · Inferenza dei modelli fondazionali**
Misurata in token. È lo strato di cui parliamo oggi, ed è il più visibile
- **2-4 · Calcolo, data center, rete**
Ore GPU, database vettoriali, 15-20 mln di dollari per megawatt, traffico in uscita (egress) fra regioni
- **5 · AI integrata nei SaaS**
Funzionalità AI dentro prodotti che non vi espongono il metro dei token
- **6-7 · Ingegneria e licenze dei dati**
Stipendi, osservabilità, valutazione, revisioni di sicurezza, corpora e diritti d'uso
- **8 · AI sommersa (Shadow AI)**
Strumenti non autorizzati e agenti non gestiti. Invisibile alla finanza, materiale in aggregato

Il token è uno strato su otto. È il più visibile, non il più grande.

J.R. Storment · Token Economics · FinOps Foundation

Dove andiamo

- 1 Capire (Inform) · l'unità di costo**
I rapporti di prezzo che contano, e potete fare i conti a mente
- 2 Capire (Inform) · dove si bruciano i token**
Agenti, contesto, strumenti, tentativi, rifacimenti. Nessuno è un problema di prezzo
- 3 Capire (Inform) · attribuire**
Demo, e poi perché oggi l'attribuzione è ancora un lavoro artigianale
- 4 Agire (Optimize) · le leve**
In ordine di ritorno, e le trappole che sembrano leve ma non lo sono
- 5 Rendere continuo (Operate) · il valore**
Il costo per risultato utile, e il nome che la disciplina gli ha già dato



Capire (Inform): l'unità di costo

Il token: l'unità di misura per cui probabilmente siete entrati qui

3/4

Di parola, in inglese

in italiano un po' meno. È
l'unità in cui vi fanno pagare

in + out

Si paga due volte

i token che mandate e quelli
che ricevete, a prezzi diversi

4-8×

Output / input

GPT-4.1 4×, GPT-5 8×
GPT-5.6 6×, GPT-6 5×

**I prezzi cambiano ogni tre mesi.
Ricordate i rapporti: dentro una famiglia sono costanti.**

L'output costa (circa) sei volte l'input

€4,30

Input · 1M token

gpt-5.6-sol contesto breve,
Global

€25,76

Output · 1M token

stesso modello, stesso
deployment

6×

Il rapporto

costante dentro GPT-5.6
GPT-6 è 5×
GPT-5 era 8×

Tagliare l'output rende sei volte più che tagliare il prompt.

Portale Azure, listino europeo

Grande contro piccolo

Modello	Input	In cache	Scrittura cache	Output
gpt-5.6-sol	€4,30	€0,43	€5,37	€25,76
gpt-5.6-terra	€1,72	€0,18	€2,15	€10,31
gpt-5.6-luna	€0,18	€0,02	€0,22	€1,04
Rapporto sol / luna	23,9×	21,5×	24,4×	24,8×

La prima leva non è ottimizzare. È scegliere.

Contesto breve, deployment Global. In contesto lungo i valori raddoppiano in input e crescono di una volta e mezza in output.

«i token di output che soddisfano un obiettivo di servizio definito (soglia di tempo al primo token + una velocità sostenuta per utente) »

Non tutti i token sono uguali: goodput contro throughput

	Cosa ottimizza	Per cosa
Massivo (Bulk)	throughput per megawatt, velocità bassa	riassunti in batch, embedding, analisi offline
Equilibrio (Goldilocks)	interattività moderata, throughput quasi ottimale	chat e applicazioni aziendali. Il punto ideale
Premium a bassa latenza	velocità per utente, throughput inferiore	agenti vocali, dove il ritardo blocca la persona
Ragionamento (Reasoning)	molti token interni per ogni token restituito	è la principale fonte della crescita di spesa

Pagare tariffe premium per carichi che tollererebbero la fascia di equilibrio è un'inefficienza misurabile.

L'obiettivo



Misurare la qualità del token, non solo la quantità. Chi traccia solo il volume sbaglia l'attribuzione del valore

Il caching in lettura

– 90%

sui token riletti dalla cache

Input in cache a 0,1× l'input su Azure, OpenAI e Google. Anthropic arriva a – 97,5% su Fable e Mythos 5.1 (poi c'è il reasoning...)

Il prefisso stabile va in testa. La parte variabile va in fondo.

Ma adesso scrivere in cache si paga

1,25×

Scrittura in cache

rispetto al prezzo dell'input, da
GPT-5.6 in avanti

0,1×

Lettura da cache

il beneficio, invariato

gratis

Prima di GPT-5.6

l'assunzione su cui molti hanno
progettato

Un sistema che invalida la cache di continuo oggi costa più di uno che non la usa.

Microsoft Learn · prompt caching su Microsoft Foundry

Il caching su Foundry, in pratica

- **La soglia è 1.024 token, e i primi 1.024 identici**
Un solo carattere diverso e `cached_tokens` torna zero. Sotto soglia non c'è caching e non c'è errore (Incrementi da 128 token 1024, 1152, 1280, 1408...9)
- **`prompt_cache_key`**
Dice al servizio quali richieste condividono il prefisso. Oltre ~15 req/min sulla stessa chiave si perdono colpi
- **Breakpoint espliciti, da GPT-5.6**
Marchiate dove finisce la parte stabile. In modalità explicit solo i vostri breakpoint sono eleggibili
- **Sui modelli precedenti: errore 400**
`prompt_cache_options` e `prompt_cache_breakpoint` non esistono. Lì c'è solo il caching automatico
- **Cosa guardare in risposta**
`cached_tokens` per le letture, `cache_write_tokens` per le scritture. Confrontate il volume delle due

Microsoft Learn · Prompt caching su Microsoft Foundry

E fuori da Foundry?

	OpenAI / Azure	Anthropic	Google
Sconto in lettura	90%	90% → 97,5%	90%
Costo di scrittura	1,25×	1,25× (5m) · 2× (1h)	nessuno
Costo a tempo	no	no	sì, storage orario
Durata	~30 min	5 min o 1 ora, a scelta	non documentata
Minimo token	1.024	da 512 a 4.096	2.048 – 4.096

Convergono sullo sconto. Divergono su come te lo fanno pagare.

Sotto la soglia minima il prompt viene processato senza caching e senza errore. Nessuno ve lo dice.

Con il contesto lungo il rapporto si ribalta

2×

Input a contesto lungo
oltre **272k token**, su tutta la
richiesta

1,5×

Output a contesto lungo
cresce meno dell'input

4,5×

Nuovo rapporto out / in
era 6× a contesto breve

A contesto lungo l'input diventa relativamente più caro. La leva si sposta.

Altre due leve che non impattano sull'implementazione

– 50%

Batch API

Target 24 ore, nessuna garanzia di tempi (SLA)

1 / 80

Batch + lettura da cache

input riletto su Fable 5.1, rispetto al listino pieno

Se nessuno sta aspettando la risposta, pagate il doppio per una fretta che non vi serve.

Listino Azure (GPT-5.4 standard €2,15 / batch €1,08) · documentazione Anthropic sul cumulo degli sconti



Capire (Inform): dove i token hanno più peso

Spoiler: non nel loro prezzo

La variabile che cambia il gioco

k

- 1 Quello che misurate**
Costo per chiamata API. È quello che vi dà il cruscotto del fornitore
- 2 Quello che paga l'utente**
Costo per richiesta utente. È il primo, moltiplicato per k
- 3 Cos'è k**
Ragionamento, riscrittura della query, recupero, chiamate a strumenti, validazione, tentativi
- 4 Perché non lo vedete**
Perché k sta nel vostro codice, non nella fattura del fornitore

Una domanda, nove chiamate: k in pratica

- 1 L'utente fa una domanda**
Una sola richiesta: è quello che vede lui, e quello che credete di pagare
- 2 Preparazione · 2 chiamate**
Un passo di ragionamento e una riscrittura della query
- 3 Recupero e azione · 5 chiamate (ovviamente questo è un dato ipotetico)**
Tre recuperi di contesto e due chiamate a strumenti
- 4 Controllo · 2 chiamate**
Una validazione e un nuovo tentativo. $k = 9$: il costo per utente è nove volte il cruscotto

Gli agenti moltiplicano

4×

Un agente

rispetto a una interazione di
chat

15×

Un sistema multi-agente

rispetto alla stessa chat

80%

Della varianza

nelle prestazioni è spiegata dal
solo uso di token

Oltre una certa soglia tagliare i token taglia la qualità. È un compromesso, non un'ottimizzazione.

Anthropic Engineering · Building a multi-agent research system

Il contesto che si trascina

- **La crescita è composta, non lineare**
Al decimo turno mandate diecimila token per riceverne duecento
- **Nelle app conversazionali domina la spesa**
Non è una voce fra le altre. È la voce principale
- **E gran parte non serve**
Pagate per rimandare al modello cose che non userà mai per questa risposta
- **Immagini e audio peggiorano il conto**
Le immagini circa 2× il testo. Audio in ingresso oltre 8× l'equivalente testuale

Il contesto che si trascina, turno dopo turno

1.000

Turno 1

token inviati al modello

10.000

Turno 10

tutta la cronologia, rimandata
ogni volta

200

La risposta

token ricevuti al decimo turno

Ogni turno rimanda tutto il passato, e quasi tutto non serve a questa risposta.

Tenetevi forte

– 98,7%

da 150.000 token a 2.000

Stesso compito, stesso modello. Cambia solo dove si svolge il lavoro rispetto alla finestra di contesto.

Il modello non deve vedere tutto. Deve vedere quello che serve per decidere.


Anthropic Engineering · Code execution with MCP

Capire (Inform): attribuire

Allocazione (Allocation): attribuire il costo a chi lo genera, e cosa vi dà Foundry

3

Cosa vi dice la fattura




Quello che avete

Una voce aggregata: quanto avete speso questo mese



Quello che vi serve

Per team, per funzionalità, per cliente, per agente



La domanda di business

Quanto mi costa servire questo cliente? Questa funzionalità sta mangiando margine?



La risposta della fattura

Nessuna

Su Foundry, dove finiscono i token lo vedete

-  **Il campo model nella risposta**
Vi dice quale modello ha servito la richiesta. Con il router è l'unico modo per saperlo. Registratelo sempre
-  **Azure Monitor, suddivisione per modello sottostante**
Portale, Monitoring e Metrics, filtro sul deployment. Vedete la distribuzione reale del traffico
-  **Cosa vi dà già la piattaforma**
Dove va la spesa fra i modelli, senza costruire niente
-  **Cosa non vi dà**
Il costo per team, per funzionalità o per cliente. Per quello serve un gateway davanti

Microsoft Learn · Monitor model router

Dal costo per modello al costo per progetto

-  **Tag di progetto automatico (anteprima)**
Ogni progetto Foundry è taggato sull'uso: in Cost analysis filtrate la spesa per progetto
-  **Il limite**
Vale per i modelli venduti da Azure, non ancora per quelli del Marketplace
-  **AI Gateway di API Management**
Limiti di token per minuto, quote per progetto e metriche per chiave, dentro Azure
-  **La divisione dei compiti**
La piattaforma dà il costo per progetto. Per funzionalità e cliente serve il gateway

Microsoft Learn · Plan and manage costs for Microsoft Foundry

I vostri abbonamenti sono aggregatori di token

Cursor

Da tariffa per richiesta a tariffa a consumo nel 2025. A parità di piano, spesa cresciuta di un ordine di grandezza per il lavoro agentico

AWS Kiro

Due classi di richiesta prezzate con rapporto cinque a uno. Gli utenti l'hanno scoperto dopo

Anthropic, aprile 2026

Impalcature di terze parti bloccate: consumavano circa 5x più calcolo per dollaro del prezzo dell'abbonamento

Cosa vuol dire per voi

Chi ha trattato gli strumenti AI come una voce SaaS ha ereditato un obbligo di consumo misurato, senza i controlli che servono

Il canone per utente (seat fee) è il pavimento. La componente variabile guida la spesa.

OpenTelemetry sa contare i token

Attributo OpenTelemetry GenAI	Cosa misura
gen_ai.usage.input_tokens	token in ingresso
gen_ai.usage.output_tokens	token in uscita
gen_ai.usage.cache_read.input_tokens	token serviti dalla cache
gen_ai.usage.cache_creation.input_tokens	token scritti in cache
gen_ai.usage.reasoning.output_tokens	token di ragionamento
nessun attributo di costo	i dollari/euro non ci sono

FOCUS sa prezzare, ma non conosce i token

1.4

Versione corrente

ratificata il 4 giugno 2026

0

Colonne sui token

nella libreria delle colonne,
nessuna

0 / 92

Casi d'uso AI

su 92 casi d'uso documentati

L'AI è dichiarata categoria tecnologica.

FOCUS, FinOps Open Cost and Usage Specification · versione 1.4 · focus.finops.org

Tre strati che non si parlano



OpenTelemetry GenAI

Conta i token. Non ha un attributo di costo



FOCUS 1.4 / 1.5

Prezzo, ma non conosce i token fino a dicembre. E poi mancheranno ragionamento, modalità e livelli



I gateway

Ognuno si inventa il proprio schema di tag. Nessuna interoperabilità



Token Cost Allocation Spec

Specifica aperta di Vantage, agosto 2026. Copre il buco, ma nasce da un fornitore

Oggi l'attribuzione ve la costruite a mano. Chi dice il contrario vi sta vendendo qualcosa che lo fa.

Cosa usare nel frattempo

Gateway davanti a tutto

1

Attribuzione per chiave, team e tag, budget e limiti di chiamate. LiteLLM, Cloudflare AI Gateway, OpenRouter

2

Osservabilità per i modelli (LLM)

Costo separato per ingresso, uscita, cache. Langfuse, Helicone, Arize Phoenix, LangSmith

3

Piattaforme FinOps

Porta il costo AI dentro il resto della spesa cloud. Vantage, CloudZero

4

Il consiglio pratico

Il gateway prima di tutto il resto. Senza un punto di passaggio unico non attribuite niente

Il routing funziona, e ci sono le cifre

Tecnica	Riduzione	Fonte
Cascata verso modelli piccoli	fino a 98%	FrugalGPT, rispetto a GPT-4 come base
Routing con dati di preferenza	oltre 85%	RouteLLM, benchmark standard
Code Mode, compiti a più passaggi	81%	Cloudflare
Code Mode, MCP con 2.500 endpoint	~99,9%	da 1,17 mln a ~1.000 token, Cloudflare
Filtro di rilevanza sul contesto	70-80%	Zilliz, con la qualità in miglioramento
CSV o TOON invece di JSON	30-60%	su dati tabellari

Il deployment a modello singolo è ormai un'inefficienza visibile.

Dove gira il dato ha un prezzo

Tipo di deployment	Dove viene processato	Prezzo
Global	qualunque regione Azure	il più basso, riferimento
Data Zone	solo dentro USA, UE o APAC. L'UE segue l'EU Data Boundary	circa +10%
Regional / Standard	dentro la geografia Azure scelta da voi	variabile per regione

Il 10% è il prezzo di tenere l'elaborazione dentro l'UE.



Il dato a riposo resta nella geografia della risorsa, con eccezioni documentate su Global

Pesi dei modelli personalizzati e cache estesa: leggete la pagina EU Data Boundary prima di firmare



I modelli nuovi arrivano prima su Global

L'ordine è Global, poi Data Zone, poi per area geografica. L'ultima non ha data garantita

Microsoft Learn · Deployment types for Microsoft Foundry Models · e listino Azure

Resa dei token (token yield rate)

resa dei token



La definizione, pubblicata

La quota di token generati che ha contribuito a un'azione di business a valle



Dopo aver contato cosa

Tentativi ripetuti, sessioni abbandonate, output che non hanno passato la revisione di qualità



Le altre cinque metriche

Costo per inferenza · efficienza di consumo dei token al livello di goodput · efficienza del costo di addestramento
· efficienza dell'inferenza · ricavo per megawatt

J.R. Storment · Token Economics · FinOps Foundation

Nel 2026 la disciplina si è scissa




FinOps Foundation

L'AI è una categoria tecnologica dentro il framework esistente, più una certificazione dedicata



Tokenomics Foundation

Lanciata dalla Linux Foundation il 4 agosto 2026. IBM, Oracle, SAP, ServiceNow, JPMorganChase



Perché due

Produrre un token e valutare quello che produce non entrano nel modello FinOps classico



« Due proiezioni dello stesso lavoro »

Mike Fuller, agosto 2026. Nessuna delle due è sottoinsieme dell'altra



E si sono viste questa settimana

Tokenomicon insieme a FinOps X Amsterdam, 22-23 settembre 2026

Cercate risposte sul costo? FinOps. Sul valore del token? Tokenomics.

Tre cose da fare usciti da questa stanza

- 1 Misurate `cached_tokens` in produzione**
Se è vicino a zero e avete un prefisso stabile, avete trovato soldi per terra
- 2 Contate `k` su una richiesta utente reale**
Quante chiamate al modello genera davvero una domanda. Anticipazione: potrebbe essere più alto di quanto pensate
- 3 Mettete un tag di attribuzione sul gateway**
Anche uno solo. Fra sei mesi vi chiederanno quanto costa una funzionalità, e indietro non si torna

E tre cose da non fare

-  **Non comprate capacità che non riempite**
A pieno utilizzo il PTU costa come la tariffa a consumo, vuoto costa di più. Si compra per la latenza e per lo SLA
-  **Non aspettate il taglio di listino**
Il costo a parità di capacità scende, il prezzo del meglio disponibile sale. Il listino non scende, si allarga
-  **Non fidatevi di una media**
Guardate la distribuzione. La spesa sta quasi sempre nella coda lunga

Il listino non scende: si allarga

\$1,25

Un anno fa

modello di punta, in ingresso,
per 1M token

€8,59

gpt-6-astra, oggi

\$10 in ingresso: il meglio costa
di più

€1,72

gpt-6-sol, tre settimane dopo

meno della metà di gpt-5.6-sol
in ingresso

Aspettare il taglio di listino senza scegliere non è una strategia.

Listino Azure europeo, Global short context



Da dove si parte e dove si arriva

« Quanto costa un token » è la domanda da cui si parte.

Quella a cui si arriva è: quanto costa un risultato che possiamo ritenere utile?

Grazie...Avete domande?



Emanuele Garofalo

Founder di Magneticode · Microsoft MVP - Azure



Grazie a 1nn0va per l'invito e l'organizzazione · #1nn0vAI2026

